

**LAPORAN MACHINE LEARNING
CHAPTER 2
SUPERVISED LEARNING**



Disusun Oleh:

Muhammad Arif Rahman Hakim

(G1A024109)

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

BAB I PENDAHULUAN

1.1 Latar Belakang

Supervised learning merupakan bagian penting dalam machine learning yang mempelajari hubungan antara data masukan dan target keluaran yang sudah diketahui. Pada Chapter 2, pembelajaran difokuskan pada masalah klasifikasi dan regresi, konsep generalisasi, overfitting dan underfitting, serta berbagai algoritma supervised learning. Notebook yang digunakan dalam praktikum menerapkan konsep tersebut secara langsung menggunakan Python, scikit-learn, mglearn, NumPy, pandas, dan matplotlib.

Percobaan pada notebook menggunakan beberapa dataset, seperti Forge, Wave, Breast Cancer, Boston Housing, two-moons, blobs, two-circles, dan Iris. Melalui dataset tersebut, berbagai model dibandingkan berdasarkan hasil prediksi, skor pada data training dan testing, serta visualisasi batas keputusan atau karakteristik model.

1.2 Rumusan Masalah

Bagaimana penerapan supervised learning pada masalah klasifikasi dan regresi, bagaimana pengaruh kompleksitas dan regularisasi terhadap generalisasi model, serta bagaimana karakteristik k-NN, model linear, Naive Bayes, Decision Tree, ensemble, SVM, neural network, dan estimasi ketidakpastian dapat diamati dari hasil notebook?

1.3 Tujuan

Laporan ini bertujuan menjelaskan setiap tahapan utama pada notebook Chapter 2, menginterpretasikan output eksperimen, dan menghubungkan hasil percobaan dengan konsep supervised learning yang dibahas dalam buku referensi.

BAB II LANDASAN TEORI

2.1 Supervised Learning

Supervised learning menggunakan pasangan input dan output yang telah diketahui. Model belajar dari data training untuk menghasilkan prediksi pada data baru. Dua bentuk utama yang

digunakan dalam Chapter 2 adalah classification, yaitu memprediksi kelas, dan regression, yaitu memprediksi nilai kontinu.

2.2 Generalisasi, Overfitting, dan Underfitting

Model tidak hanya perlu cocok terhadap data training, tetapi juga harus mampu bekerja pada data yang belum pernah dilihat. Overfitting terjadi ketika model terlalu menyesuaikan diri dengan training data sehingga performa pada data baru menurun. Underfitting terjadi ketika model terlalu sederhana sehingga pola penting pada data belum dipelajari dengan baik.

2.3 k-Nearest Neighbors

k-NN menentukan prediksi berdasarkan kedekatan sebuah sampel dengan sejumlah tetangga terdekat. Nilai k yang kecil menghasilkan model yang lebih kompleks, sedangkan nilai k yang lebih besar membuat batas keputusan lebih halus. Pada regresi, prediksi dapat diperoleh dari rata-rata target tetangga.

2.4 Model Linear

Model linear menggunakan kombinasi linear fitur untuk menghasilkan prediksi. LinearRegression digunakan untuk regresi, sedangkan LogisticRegression dan LinearSVC digunakan untuk klasifikasi. Ridge dan Lasso menambahkan regularisasi untuk mengendalikan kompleksitas model.

2.5 Naive Bayes

Naive Bayes menggunakan probabilitas kelas dan probabilitas fitur dengan asumsi independensi bersyarat antarfitur. Pada notebook, konsep perhitungan jumlah fitur ditunjukkan melalui contoh data biner sederhana.

2.6 Decision Tree

Decision Tree membuat keputusan melalui serangkaian pemisahan data berdasarkan fitur. Keunggulannya adalah struktur model relatif mudah divisualisasikan dan tidak sensitif terhadap skala fitur, tetapi pohon yang terlalu kompleks dapat overfitting.

2.7 Ensemble Decision Tree

Ensemble menggabungkan beberapa model untuk membentuk model yang lebih kuat. Notebook membahas Random Forest dan Gradient Boosting. Random Forest membangun banyak tree

dengan unsur randomisasi, sedangkan Gradient Boosting membangun model secara bertahap untuk memperbaiki kesalahan model sebelumnya.

2.8 Support Vector Machine

SVM mencari batas pemisah antar kelas dengan margin tertentu. Kernel seperti RBF memungkinkan SVM menangani pola non-linear. Parameter seperti C dan gamma memengaruhi kompleksitas model dan bentuk batas keputusan.

2.9 Neural Networks

Neural network terdiri dari unit yang tersusun dalam layer dan menggunakan fungsi aktivasi untuk mempelajari hubungan non-linear. Notebook menggunakan MLPClassifier serta membandingkan jumlah hidden layer, jumlah unit, fungsi aktivasi, dan regularisasi.


2.10 Uncertainty Estimates

Model klasifikasi dapat memberikan decision function sebagai skor relatif terhadap batas keputusan dan probabilitas kelas melalui predict_proba. Pada klasifikasi multiclass, model menghasilkan skor atau probabilitas untuk setiap kelas.


BAB III PEMBAHASAN DAN HASIL

3.1 Persiapan Lingkungan dan Dataset

Notebook diawali dengan pengunduhan preamble dan pemasangan mglearn. Setelah itu, beberapa dataset disiapkan untuk menunjukkan perbedaan karakteristik supervised learning. Dataset Forge digunakan untuk klasifikasi sederhana, Wave untuk regresi, Breast Cancer untuk klasifikasi dengan banyak fitur, dan Boston Housing untuk regresi dengan fitur yang lebih kompleks.




Gambar 3.1. Visualisasi dataset Forge.



Gambar 3.2. Visualisasi dataset Wave.


3.2 Penerapan k-Nearest Neighbors

Pada klasifikasi Forge, model `KNeighborsClassifier` dengan tiga tetangga dilatih menggunakan data training. Prediksi pada data testing menghasilkan akurasi 0,86. Notebook juga memperlihatkan bahwa perubahan jumlah tetangga mengubah bentuk batas keputusan. Dengan satu tetangga, model mengikuti data lebih dekat; dengan lebih banyak tetangga, batas keputusan menjadi lebih halus.



Gambar 3.2. Perbandingan batas keputusan k-NN untuk beberapa nilai jumlah tetangga.

Pada regresi, KNeighborsRegressor dengan tiga tetangga diterapkan pada dataset Wave. Prediksi testing ditampilkan secara numerik dan menghasilkan skor R^2 sebesar 0,83. Perbandingan visual untuk satu, tiga, dan sembilan tetangga menunjukkan bagaimana nilai k memengaruhi kehalusan prediksi.




Gambar 3.3. Pengaruh jumlah tetangga pada k-NN regression.

3.3 Model Linear untuk Regresi


LinearRegression pada dataset Wave menghasilkan koefisien sekitar 0,394 dan intercept sekitar -0,032. Skor training sebesar 0,67 dan testing sebesar 0,66 menunjukkan bahwa model sederhana tersebut memiliki performa yang relatif serupa pada kedua bagian data.

Ketika diterapkan pada extended Boston dataset, LinearRegression menghasilkan skor training 0,95 tetapi test 0,61. Perbedaan ini menunjukkan bahwa model dapat terlalu menyesuaikan diri dengan training data. Untuk mengatasi kompleksitas tersebut, notebook membandingkan Ridge dan Lasso.



Gambar 3.4. Perbandingan koefisien model linear dan Ridge.


Ridge dengan $\alpha=1$ menghasilkan skor 0,89 pada training dan 0,75 pada test. Saat α dinaikkan menjadi 10, skor menjadi 0,79 dan 0,64. Sementara $\alpha=0,1$ menghasilkan 0,93 dan 0,77. Lasso dengan α default menghasilkan skor yang rendah, sedangkan $\alpha=0,01$ menghasilkan 0,90 pada training dan 0,77 pada test. Dengan $\alpha=0,0001$, training meningkat menjadi 0,95 tetapi test menjadi 0,64. Hasil tersebut memperlihatkan pentingnya memilih kekuatan regularisasi yang sesuai.



Gambar 3.5. Perbandingan koefisien Ridge dan Lasso.

3.4 Model Linear untuk Klasifikasi

Notebook membandingkan LogisticRegression dan LinearSVC sebagai model linear untuk klasifikasi. Pada Breast Cancer dataset, LogisticRegression dengan konfigurasi dasar menghasilkan training accuracy 0,944 dan test accuracy 0,958. Perubahan parameter C digunakan untuk memperlihatkan pengaruh regularisasi. Dengan C=100, test accuracy tetap 0,958, sedangkan C=0,01 menghasilkan test accuracy 0,930.




Gambar 3.6. Koefisien Logistic Regression untuk beberapa nilai C.

Notebook juga menggunakan regularisasi L1 pada LogisticRegression. Dengan $C=0,001$, hasil yang tercatat adalah training accuracy 0,91 dan test accuracy 0,92. Regularisasi L1 dapat membuat sebagian koefisien menjadi nol sehingga model sekaligus dapat melakukan seleksi fitur.


3.5 Naive Bayes dan Decision Tree

Konsep Naive Bayes diperlihatkan melalui data biner sederhana. Notebook menghitung jumlah kemunculan fitur untuk masing-masing kelas. Contoh tersebut memperlihatkan bagaimana informasi fitur dapat dihitung secara terpisah menurut kelas sebagai dasar pendekatan probabilistik.



Gambar 3.7. Ilustrasi struktur Decision Tree.


DecisionTreeClassifier kemudian diterapkan pada Breast Cancer. Tanpa pembatasan kedalaman, akurasi training mencapai 1,000 sedangkan test 0,937. Ketika max_depth dibatasi menjadi 4, training menjadi 0,988 dan test menjadi 0,951. Perubahan tersebut memperlihatkan bahwa pembatasan kompleksitas tree dapat membantu generalisasi.



Gambar 3.9. Feature importance Decision Tree.


3.6 Decision Tree Regression dan Ensemble

Notebook menggunakan data historis harga RAM untuk membandingkan prediksi DecisionTreeRegressor dan LinearRegression. Grafik menunjukkan perbedaan perilaku kedua model pada data historis dan periode setelah tahun 2000.




Gambar 3.10 Perbandingan prediksi Decision Tree dan Linear Regression pada harga RAM.

Random Forest diterapkan pada dataset two-moons dan Breast Cancer. Dengan 100 tree pada Breast Cancer, training accuracy mencapai 1,000 dan test accuracy 0,972. Gradient Boosting dengan konfigurasi default menghasilkan test 0,965; max_depth=1 menghasilkan 0,972; sedangkan learning_rate=0,01 menghasilkan 0,958.




Gambar 3.11. Partisi yang dihasilkan beberapa tree dalam Random Forest.




Gambar 3.12. Feature importance Random Forest.

3.7 Kernelized Support Vector Machine

Notebook menunjukkan bahwa LinearSVC tidak selalu mampu memisahkan data dengan pola non-linear. Feature engineering dengan menambahkan fitur kuadrat mengubah representasi data sehingga separator linear dapat digunakan pada ruang fitur yang lebih tinggi.




Gambar 3.13. Transformasi fitur dengan penambahan fitur kuadrat.




Gambar 3.14. SVM dengan kernel RBF pada data non-linear.

SVC dengan kernel RBF kemudian diuji menggunakan berbagai kombinasi C dan γ . Pada Breast Cancer tanpa scaling, SVC menghasilkan training accuracy 0,90 dan test accuracy 0,94. Notebook kemudian memperlihatkan bahwa fitur-fitur Breast Cancer memiliki skala yang sangat berbeda.



Gambar 3.15. Perbedaan magnitudo antarfitur Breast Cancer.


Setelah min-max scaling menggunakan parameter yang dihitung dari training set, SVC menghasilkan training accuracy 0,984 dan test accuracy 0,972. Saat C dinaikkan menjadi 1000, training menjadi 1,000 tetapi test turun menjadi 0,958. Hasil ini menunjukkan bahwa scaling dan pengaturan kompleksitas merupakan bagian penting dalam penggunaan SVM.




Gambar 3.16. Pengaruh C dan gamma terhadap SVM RBF.

3.8 Neural Network / Multilayer Perceptron

Notebook memperkenalkan neural network melalui diagram arsitektur dan fungsi aktivasi. Fungsi tanh dan ReLU dibandingkan secara visual, kemudian MLPClassifier digunakan pada dataset two-moons. Jumlah hidden layer, jumlah unit, dan regularisasi alpha diubah untuk melihat pengaruhnya terhadap batas keputusan.




Gambar 3.17. Perbandingan fungsi aktivasi tanh dan ReLU.



Gambar 3.18. Pengaruh jumlah hidden nodes dan regularisasi pada MLP.


Pada Breast Cancer, MLP tanpa scaling menghasilkan training accuracy 0,94 dan test 0,92. Setelah standardization berdasarkan mean dan standar deviasi training set, hasil meningkat menjadi training 0,991 dan test 0,965. Dengan max_iter=1000, test accuracy mencapai 0,972. Penambahan alpha=1 menghasilkan training 0,988 dan test 0,972.



Gambar 3.19. Visualisasi bobot layer pertama MLP.


3.9 Decision Function dan Probabilitas

Bagian akhir notebook membahas estimasi ketidakpastian model. Pada klasifikasi biner, `decision_function` menghasilkan satu skor untuk setiap sampel. Skor ini dapat dibandingkan dengan threshold nol untuk memperoleh prediksi kelas.



Gambar 3.20. Visualisasi decision function pada ruang fitur.

Notebook juga menggunakan `predict_proba` untuk memperoleh probabilitas masing-masing kelas. Pada klasifikasi biner, output memiliki dua probabilitas per sampel dan jumlah keduanya adalah satu. Pada Iris yang merupakan multiclass, `decision_function` dan probabilitas menghasilkan satu nilai untuk setiap kelas, kemudian ``argmax`` digunakan untuk mengambil kelas dengan skor atau probabilitas terbesar.



Gambar 3.21. Perbandingan decision function dan probabilitas prediksi.

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan seluruh percobaan pada notebook, supervised learning dapat diterapkan untuk klasifikasi maupun regresi menggunakan berbagai algoritma. k-NN menunjukkan pengaruh langsung jumlah tetangga terhadap kompleksitas model. Model linear menunjukkan pentingnya regularisasi melalui Ridge dan Lasso. Logistic Regression dan LinearSVC memberikan pendekatan linear untuk klasifikasi, sedangkan Decision Tree dan ensemble mampu membentuk aturan yang lebih fleksibel.

SVM dengan kernel RBF dapat menangani pola non-linear, tetapi sensitif terhadap skala fitur sehingga preprocessing menjadi penting. Neural network juga menunjukkan peningkatan performa setelah fitur distandarisasi. Secara keseluruhan, hasil notebook memperlihatkan bahwa pemilihan algoritma, pengaturan kompleksitas, regularisasi, scaling, dan evaluasi pada data testing merupakan bagian yang saling berkaitan dalam membangun model supervised learning.

4.2 Saran

Pada pengembangan berikutnya, setiap model dapat diuji menggunakan cross-validation dan pencarian parameter secara sistematis agar pemilihan hyperparameter tidak hanya bergantung pada satu pembagian data. Selain itu, metrik evaluasi dapat disesuaikan dengan jenis masalah dan karakteristik dataset.

DAFTAR PUSTAKA

Müller, Andreas C., dan Sarah Guido. 2017. Introduction to Machine Learning with Python: A Guide for Data Scientists. O'Reilly Media, Inc. ISBN 978-1-449-36941-5.

Sumber utama pembahasan dan hasil eksperimen: notebook Machine_Learning_CH_2.ipynb yang digunakan dalam praktikum.