

LAPORAN MACHINE LEARNING
UNSUPERVISED LEARNING DAN PREPROCESSING
BAB 3



Disusun Oleh:

Muhammad Arif Rahman Hakim

(G1A024109)

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

BAB I

PENDAHULUAN

1.1 Latar Belakang

Machine learning tidak hanya digunakan untuk melakukan prediksi berdasarkan data yang sudah memiliki label, tetapi juga dapat digunakan untuk menemukan pola dari data yang belum memiliki keluaran yang diketahui. Pendekatan tersebut dikenal sebagai unsupervised learning. Pada pendekatan ini, algoritma menerima data masukan dan berusaha menemukan struktur, representasi, atau kelompok yang terdapat di dalam data.

Bab 3 membahas dua bagian utama, yaitu transformasi data dan clustering. Transformasi data digunakan untuk menghasilkan representasi baru yang lebih sederhana atau lebih sesuai untuk analisis, sedangkan clustering digunakan untuk membagi data ke dalam kelompok berdasarkan kemiripan. Selain itu, preprocessing dan scaling menjadi bagian penting karena karakteristik skala data dapat memengaruhi hasil algoritma machine learning.

Pada praktikum ini, konsep-konsep tersebut diterapkan menggunakan Python dan scikit-learn melalui beberapa dataset, seperti Breast Cancer, Labeled Faces in the Wild, dan Digits. Percobaan mencakup scaling, PCA, NMF, t-SNE, k-Means, Agglomerative Clustering, DBSCAN, serta beberapa metode evaluasi clustering.

1.2 Rumusan Masalah

- Bagaimana preprocessing dan scaling memengaruhi representasi data sebelum digunakan dalam machine learning?
- Bagaimana PCA, NMF, dan t-SNE digunakan untuk melakukan transformasi atau reduksi dimensi data?
- Bagaimana k-Means, Agglomerative Clustering, dan DBSCAN melakukan pengelompokan data?
- Bagaimana hasil clustering dapat dievaluasi menggunakan ARI, NMI, dan silhouette score?

1.3 Tujuan

- Memahami konsep unsupervised learning dan preprocessing pada Bab 3.
- Menerapkan teknik scaling dan transformasi data menggunakan scikit-learn.
- Mengamati penerapan PCA, NMF, dan t-SNE pada data berdimensi tinggi.
- Menerapkan dan membandingkan beberapa algoritma clustering.
- Memahami cara mengevaluasi hasil clustering berdasarkan karakteristik dataset.

BAB II

LANDASAN TEORI

2.1 Unsupervised Learning

Unsupervised learning merupakan pendekatan machine learning yang tidak menggunakan target atau label sebagai keluaran yang harus diprediksi. Algoritma menerima data masukan dan berusaha menemukan pola atau struktur yang terdapat di dalamnya. Berdasarkan materi Chapter 3, bentuk utama yang dibahas adalah transformasi data dan clustering.

2.2 Preprocessing dan Scaling

Preprocessing merupakan tahap menyiapkan data agar lebih sesuai dengan kebutuhan algoritma. Salah satu bentuk preprocessing adalah scaling, yaitu mengubah skala fitur. StandardScaler membuat fitur memiliki rata-rata mendekati nol dan varians satu, sedangkan MinMaxScaler mengubah nilai fitur berdasarkan rentang minimum dan maksimum sehingga data training berada pada rentang 0 sampai 1. RobustScaler menggunakan median dan kuartil sehingga lebih tahan terhadap outlier, sementara Normalizer melakukan penskalaan berdasarkan panjang vektor setiap sampel.

2.3 Principal Component Analysis (PCA)

PCA merupakan teknik reduksi dimensi yang mencari komponen baru yang mampu menjelaskan variasi terbesar pada data. Data berdimensi tinggi dapat direpresentasikan dengan jumlah komponen yang lebih sedikit. PCA dapat digunakan untuk visualisasi, mengurangi kompleksitas data, dan menghasilkan representasi yang lebih ringkas.

2.4 Non-Negative Matrix Factorization (NMF)

NMF melakukan dekomposisi data menjadi komponen dan koefisien yang bernilai non-negatif. Karena seluruh nilai harus non-negatif, metode ini cocok untuk data seperti gambar atau sinyal yang dapat direpresentasikan sebagai kombinasi penjumlahan beberapa sumber. Komponen NMF sering lebih mudah diinterpretasikan sebagai bagian atau pola tertentu.

2.5 Manifold Learning dengan t-SNE

t-SNE merupakan metode manifold learning yang terutama digunakan untuk visualisasi data berdimensi tinggi ke dalam dua dimensi. Metode ini berusaha mempertahankan hubungan kedekatan antar titik, terutama hubungan lokal. Karena t-SNE pada scikit-learn tidak menyediakan transform untuk data baru, proses biasanya dilakukan dengan `fit_transform` pada data yang akan divisualisasikan.

2.6 Clustering

Clustering adalah proses membagi data ke dalam beberapa kelompok berdasarkan kemiripan. Berbeda dari klasifikasi, nomor cluster tidak memiliki makna bawaan. Cluster 0 dan cluster 1, misalnya, dapat bertukar nomor tanpa mengubah struktur pengelompokan.

2.7 k-Means

k-Means mencari sejumlah pusat cluster atau centroid. Data kemudian ditempatkan pada centroid terdekat dan centroid diperbarui berdasarkan rata-rata data yang menjadi anggotanya. Proses tersebut diulang sampai pembagian cluster stabil. Metode ini sederhana dan cepat, tetapi lebih sesuai untuk cluster yang bentuknya relatif kompak.

2.8 Agglomerative Clustering

Agglomerative Clustering merupakan hierarchical clustering yang dimulai dengan setiap data sebagai cluster tersendiri. Cluster yang berdekatan kemudian digabung secara bertahap. Hasil penggabungan dapat dilihat menggunakan dendrogram sehingga struktur hierarki data dapat dianalisis.

2.9 DBSCAN

DBSCAN mengelompokkan data berdasarkan kepadatan. Dua parameter utamanya adalah `eps` dan `min_samples`. `eps` menentukan radius pencarian tetangga, sedangkan `min_samples` menentukan jumlah minimum titik yang dibutuhkan agar suatu area dianggap cukup padat. Data yang tidak masuk ke cluster dapat diberi label -1 sebagai noise.

2.10 Evaluasi Clustering

Evaluasi clustering tidak selalu mudah karena biasanya tidak tersedia label sebenarnya. Jika ground truth tersedia, Adjusted Rand Index (ARI) dan Normalized Mutual Information (NMI) dapat digunakan. Jika ground truth tidak tersedia, silhouette score dapat digunakan untuk mengukur kekompakan dan pemisahan cluster, tetapi hasilnya tetap perlu dilihat bersama karakteristik struktur data.

BAB III

PEMBAHASAN DAN HASIL

3.1 Persiapan Lingkungan dan Dataset

Praktikum diawali dengan menyiapkan library dan konfigurasi visualisasi yang digunakan selama proses pembelajaran. Notebook memanfaatkan scikit-learn untuk dataset, preprocessing, reduksi dimensi, clustering, dan evaluasi, serta mglearn untuk beberapa ilustrasi yang mengikuti materi buku. Dataset yang digunakan tidak hanya satu, tetapi disesuaikan dengan contoh pada setiap topik agar karakteristik algoritma dapat diamati secara lebih jelas.


3.2 Preprocessing dan Min-Max Scaling

Dataset Breast Cancer terdiri dari 569 sampel dengan 30 fitur. Data dibagi menjadi 426 data training dan 143 data testing. MinMaxScaler kemudian dipelajari menggunakan data training melalui `fit()`. Setelah itu, `transform()` digunakan untuk mengubah data training dan data testing dengan parameter yang sama.

Hasil transformasi menunjukkan bahwa bentuk data training tetap (426, 30), karena scaling tidak mengurangi jumlah fitur. Pada data training, nilai minimum setiap fitur setelah scaling

menjadi 0 dan nilai maksimum menjadi 1. Hal ini menunjukkan bahwa MinMaxScaler berhasil mengubah skala fitur berdasarkan karakteristik data training.

Hal penting dari percobaan ini adalah data testing tidak boleh dibuatkan scaler baru. Parameter minimum dan maksimum harus dipelajari dari data training kemudian digunakan kembali pada data testing. Dengan cara ini, proses preprocessing tidak menggunakan informasi dari data testing untuk membentuk transformasi.



Gambar 3.1 Visualisasi perbandingan beberapa metode scaling

3.3 Pengaruh Preprocessing terhadap SVM

Pengaruh scaling diuji menggunakan Support Vector Machine pada dataset Breast Cancer. Ketika SVM dilatih pada data asli dengan $C=100$, akurasi test yang diperoleh dari notebook adalah 0,94. Setelah menggunakan MinMaxScaler, akurasi meningkat menjadi 0,97. Ketika StandardScaler digunakan, akurasi yang diperoleh adalah 0,96.

Hasil tersebut memperlihatkan bahwa skala fitur dapat memengaruhi kinerja SVM secara nyata. Fitur pada dataset memiliki rentang nilai yang berbeda-beda, sehingga proses scaling membantu membuat representasi data lebih sesuai untuk algoritma yang sensitif terhadap skala.

3.4 Principal Component Analysis (PCA) pada Breast Cancer

PCA digunakan untuk mengubah data Breast Cancer dari 30 fitur menjadi dua komponen utama. Hasil notebook menunjukkan perubahan bentuk dari (569, 30) menjadi (569, 2). Dengan dua komponen tersebut, data dapat divisualisasikan dalam scatter plot dua dimensi.


Komponen PCA merupakan kombinasi dari fitur-fitur asli dengan bobot tertentu. Notebook juga menampilkan bentuk komponen sebesar (2, 30), yang berarti terdapat dua komponen utama dan masing-masing dibentuk dari 30 fitur asli. Dengan demikian, PCA memberikan representasi yang lebih sederhana tanpa mempertahankan seluruh fitur awal secara langsung.

3.5 PCA pada Dataset Wajah

Percobaan berikutnya menggunakan dataset Labeled Faces in the Wild. Dataset yang dipakai pada notebook memiliki 3023 gambar dengan ukuran 87×65 piksel dan 62 kelas. Data gambar kemudian digunakan untuk klasifikasi sederhana dengan K-Nearest Neighbors sebagai pembandingan.

Pada representasi awal, skor test 1-nearest-neighbor yang diperoleh adalah 0,22. Data kemudian direduksi menggunakan PCA dengan 100 komponen dan whitening. Hasil transformasi menunjukkan ukuran `X_train_pca` sebesar (1547, 100), sehingga jumlah fitur jauh lebih kecil dibandingkan representasi piksel awal. Setelah PCA, akurasi test meningkat menjadi 0,30.

Peningkatan tersebut menunjukkan bahwa representasi baru hasil PCA dapat membantu model pada percobaan ini. PCA juga memungkinkan komponen-komponen utama divisualisasikan kembali sebagai bentuk gambar. Komponen tersebut dapat menangkap pola seperti pencahayaan, kontras, atau struktur umum wajah.



Gambar 3.5 Contoh hasil rekonstruksi/representasi wajah setelah PCA



Gambar 3.4 Contoh gambar pada dataset Labeled Faces in the Wild

3.6 Non-Negative Matrix Factorization (NMF)


NMF digunakan untuk menemukan komponen yang seluruh nilainya non-negatif. Pada dataset wajah, notebook mencoba beberapa jumlah komponen untuk melihat pengaruhnya terhadap rekonstruksi gambar. Dengan 15 komponen, pola komponen terlihat seperti prototipe atau bagian wajah tertentu.

Notebook juga mengurutkan gambar berdasarkan nilai komponen tertentu. Hal ini membantu menunjukkan bahwa komponen NMF dapat memiliki pola yang cukup mudah diinterpretasikan. Misalnya, beberapa komponen dapat lebih kuat pada gambar dengan arah wajah tertentu.

NMF juga diterapkan pada data sinyal. Tiga sinyal sumber dibuat terlebih dahulu, kemudian dicampurkan menjadi 100 pengukuran sehingga menghasilkan data berukuran (2000, 100). NMF digunakan untuk memulihkan tiga sumber tersebut dan menghasilkan bentuk (2000, 3). Percobaan ini menunjukkan penggunaan NMF untuk memisahkan pola atau sumber yang bercampur.

3.7 Perbandingan NMF dan PCA pada Sinyal

Pada data sinyal yang sama, PCA dengan tiga komponen digunakan sebagai pembandingan. Hasil visualisasi menunjukkan bahwa NMF dapat memulihkan pola sumber dengan cukup baik, sedangkan PCA menghasilkan representasi yang berbeda. Perbedaan tersebut sesuai dengan karakteristik kedua metode: PCA mencari arah yang menjelaskan variasi data, sedangkan NMF membatasi komponen dan koefisien agar tetap non-negatif.



Gambar 3.7 Perbandingan sinyal observasi, sinyal asli, hasil NMF, dan matriks pencampur

3.8 Manifold Learning dengan t-SNE

Dataset Digits digunakan untuk membandingkan visualisasi PCA dan t-SNE. Data berisi gambar digit tulisan tangan yang direpresentasikan sebagai fitur piksel. PCA digunakan terlebih dahulu untuk menghasilkan dua komponen utama, kemudian hasilnya diplot berdasarkan kelas digit.

Selanjutnya t-SNE digunakan untuk menghasilkan representasi dua dimensi. Dibandingkan PCA, t-SNE pada percobaan ini memberikan pemisahan kelompok digit yang lebih jelas secara visual. Hal tersebut menunjukkan bahwa t-SNE dapat mempertahankan hubungan lokal yang tidak selalu dapat terlihat dengan baik menggunakan proyeksi linear seperti PCA.

Namun, t-SNE terutama ditujukan untuk eksplorasi dan visualisasi. Hasil visual yang tampak terpisah tidak secara otomatis berarti bahwa representasi tersebut merupakan fitur terbaik untuk model supervised learning.

3.9 Penerapan k-Means

k-Means diuji menggunakan data sintetis dari `make_blobs`. Model dibuat dengan `n_clusters=3` dan kemudian dilatih menggunakan `fit()`. Setiap data memperoleh label cluster yang

ditampilkan melalui atribut `labels_`. Model juga dapat digunakan untuk memberi label pada data menggunakan `predict()`.

Visualisasi menunjukkan posisi anggota cluster dan centroid. Notebook juga mencoba jumlah cluster yang berbeda, yaitu dua dan lima cluster. Percobaan tersebut memperlihatkan bahwa perubahan nilai `n_clusters` akan mengubah pembagian data, sehingga jumlah cluster harus dipilih sesuai tujuan dan karakteristik data.

k-Means juga diuji pada data dengan kepadatan berbeda, data yang diregangkan, dan data two-moons. Hasil percobaan menunjukkan keterbatasan k-Means pada cluster yang tidak berbentuk bulat atau memiliki bentuk kompleks. Pada two-moons, k-Means tidak dapat mengikuti dua bentuk setengah lingkaran dengan baik karena keputusan cluster didasarkan pada jarak terhadap centroid.

3.10 k-Means sebagai Vector Quantization

k-Means juga dapat dipandang sebagai metode representasi atau vector quantization. Setiap data direpresentasikan berdasarkan centroid yang paling dekat. Pada data two-moons, notebook menggunakan 10 cluster sehingga setiap data memperoleh salah satu dari 10 label.


Selain label cluster, k-Means dapat menghasilkan fitur berupa jarak setiap data terhadap seluruh centroid menggunakan `transform()`. Hasil notebook menunjukkan bentuk distance feature sebesar (200, 10). Dengan demikian, data dua dimensi dapat direpresentasikan menggunakan 10 fitur jarak yang menggambarkan kedekatan terhadap pusat-pusat cluster.

3.11 Agglomerative Clustering


Agglomerative Clustering diterapkan sebagai metode hierarchical clustering. Data awalnya dianggap sebagai kelompok-kelompok kecil yang kemudian digabung berdasarkan kedekatan. Dendrogram digunakan untuk memperlihatkan urutan dan jarak penggabungan tersebut.

Pada dataset wajah yang telah direduksi dengan PCA, Agglomerative Clustering digunakan dengan 10 cluster. Notebook memperoleh ukuran cluster [264, 100, 275, 553, 49, 64, 546, 52, 51, 109]. Hasil tersebut menunjukkan bahwa ukuran cluster dapat berbeda cukup besar tergantung struktur data dan proses penggabungan.

Dendrogram membantu melihat struktur hierarki dan kemungkinan titik pemotongan untuk menentukan jumlah cluster. Berbeda dengan k-Means, Agglomerative Clustering tidak memiliki centroid yang secara langsung mewakili setiap cluster.



Gambar 3.12 Dendrogram hasil Agglomerative Clustering




Gambar 3.11 Tahapan Agglomerative Clustering

3.12 DBSCAN


DBSCAN diterapkan pada beberapa dataset untuk memperlihatkan cara kerja clustering berbasis kepadatan. Pada data two-moons, DBSCAN dapat menemukan struktur cluster yang mengikuti bentuk data dan sekaligus dapat menandai beberapa titik sebagai noise.

Notebook juga menguji pengaruh eps dan min_samples. Pada data wajah setelah PCA, penggunaan parameter default menghasilkan semua data dengan label -1. Ketika min_samples diturunkan menjadi 3, hasil tersebut masih sama. Setelah eps dinaikkan menjadi 15, terbentuk satu cluster besar dan data noise. Notebook kemudian mencoba beberapa nilai eps untuk melihat perubahan jumlah cluster dan ukuran cluster.

Pada percobaan tersebut, perubahan eps menghasilkan struktur yang berbeda. Nilai eps yang terlalu kecil menyebabkan banyak data dianggap noise, sedangkan nilai yang lebih besar menggabungkan lebih banyak data ke dalam cluster. Hal ini menunjukkan bahwa pemilihan parameter DBSCAN sangat berpengaruh terhadap hasil akhir.



Gambar 3.14 Hasil DBSCAN pada data two-moons




Gambar 3.13 Ilustrasi konsep DBSCAN

3.13 Evaluasi Clustering

Adjusted Rand Index (ARI) digunakan untuk membandingkan hasil clustering dengan label atau pembagian yang diketahui. Notebook menunjukkan bahwa accuracy tidak tepat digunakan secara langsung untuk clustering. Dua pengelompokan dapat memiliki struktur yang sama meskipun nomor labelnya berbeda. Pada contoh, accuracy menghasilkan 0,00 sedangkan ARI menghasilkan 1,00 karena kedua pengelompokan sebenarnya identik setelah nomor cluster ditukar.

Silhouette score digunakan ketika ground truth tidak tersedia. Nilai tersebut mempertimbangkan kedekatan data dengan cluster sendiri dibandingkan dengan cluster lain. Namun, percobaan pada two-moons menunjukkan keterbatasannya: metode dengan bentuk cluster kompak dapat memperoleh silhouette lebih tinggi meskipun secara visual DBSCAN lebih sesuai dengan struktur two-moons. Oleh karena itu, evaluasi clustering tidak sebaiknya hanya bergantung pada satu metrik.

Pada dataset wajah, ARI antara hasil Agglomerative Clustering dan k-Means yang diperoleh notebook adalah 0,09. Nilai tersebut menunjukkan bahwa dua pembagian cluster tersebut memiliki kesamaan yang rendah. Perbedaan tersebut dapat terjadi karena kedua algoritma menggunakan prinsip pengelompokan yang berbeda.




Gambar 3.15 Visualisasi silhouette coefficient

3.14 Perbandingan Metode Clustering pada Dataset Wajah


Setelah data wajah direduksi menjadi 100 komponen PCA, tiga algoritma clustering dibandingkan. DBSCAN dapat menghasilkan noise dalam jumlah besar dan cluster yang bergantung kuat pada eps. k-Means membagi seluruh data ke sejumlah cluster yang ditentukan, sedangkan Agglomerative Clustering membentuk struktur hierarki berdasarkan proses penggabungan.

Pada percobaan k-Means dengan 10 cluster, ukuran cluster yang dihasilkan cukup bervariasi, termasuk cluster yang sangat kecil. Pada Agglomerative Clustering dengan 10 cluster, ukuran cluster juga berbeda-beda. Visualisasi cluster center k-Means memperlihatkan pola wajah yang lebih halus karena centroid merupakan rata-rata dari anggota cluster.

Percobaan ini memperlihatkan bahwa tidak ada satu algoritma clustering yang secara otomatis cocok untuk semua jenis data. Hasil perlu dianalisis berdasarkan bentuk data, kepadatan, kebutuhan terhadap noise, dan tujuan pengelompokan.



Gambar 3.17 Hasil pengelompokan wajah menggunakan Agglomerative Clustering



Gambar 3.16 Hasil pengelompokan wajah menggunakan k-Means

BAB IV

PENUTUP

4.1 Kesimpulan

Berdasarkan praktikum Bab 3, unsupervised learning digunakan untuk menemukan pola, struktur, atau representasi baru dari data tanpa menggunakan target sebagai acuan utama. Tahap preprocessing, khususnya scaling, menjadi bagian penting karena perbedaan skala fitur dapat memengaruhi algoritma tertentu. Pada percobaan SVM menggunakan dataset Breast Cancer, akurasi meningkat dari 0,94 pada data asli menjadi 0,97 setelah MinMaxScaler dan 0,96 setelah StandardScaler.

PCA berhasil mengurangi dimensi data, misalnya dari 30 fitur menjadi dua komponen pada dataset Breast Cancer dan menjadi 100 komponen pada dataset wajah. NMF memberikan representasi berbasis komponen non-negatif dan dapat digunakan untuk menemukan pola atau memisahkan sumber yang bercampur. t-SNE menghasilkan visualisasi dua dimensi yang pada dataset Digits mampu memperlihatkan pemisahan kelas dengan lebih jelas dibandingkan PCA.

Pada bagian clustering, k-Means bekerja dengan centroid dan cocok untuk kelompok yang relatif kompak, tetapi memiliki keterbatasan pada bentuk cluster yang kompleks. Agglomerative Clustering membentuk struktur hierarki yang dapat dianalisis melalui dendrogram. DBSCAN

menggunakan kepadatan dan dapat mengenali noise, tetapi hasilnya sangat bergantung pada parameter `eps` dan `min_samples`.

Evaluasi clustering juga memiliki tantangan tersendiri. ARI dan NMI dapat digunakan ketika label pembanding tersedia, sedangkan silhouette score dapat digunakan tanpa ground truth tetapi memiliki keterbatasan pada struktur cluster yang kompleks. Oleh karena itu, pemilihan metode preprocessing, transformasi, clustering, dan evaluasi harus disesuaikan dengan karakteristik data serta tujuan analisis.

4.2 Saran

Pada penerapan berikutnya, pemilihan parameter algoritma dapat dilakukan secara lebih sistematis dan hasil setiap metode dapat dibandingkan menggunakan beberapa ukuran evaluasi sekaligus. Visualisasi juga tetap perlu digunakan untuk membantu memahami struktur data, terutama pada unsupervised learning karena tidak selalu tersedia jawaban benar yang dapat digunakan sebagai acuan.

DAFTAR PUSTAKA

Müller, A. C., & Guido, S. (2017). *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media.

scikit-learn Developers. (2026). Scikit-learn documentation. <https://scikit-learn.org/>