

## **PEMBAHASAN BAB 3**

### **UNSUPERVISED LEARNING AND PREPROCESSING**

Nama : Muhammad Arif Rahman Hakim

NPM : G1A024109

Pada Bab 3 dibahas mengenai unsupervised learning dan beberapa teknik yang digunakan untuk melakukan pengolahan serta analisis data tanpa menggunakan label sebagai acuan utama. Berbeda dengan supervised learning yang menggunakan data berlabel untuk proses pembelajaran, unsupervised learning digunakan untuk menemukan pola, struktur, atau kelompok yang terdapat di dalam data. Teknik ini dapat digunakan untuk membantu memahami karakteristik data sebelum dilakukan proses analisis atau pemodelan lebih lanjut.

Salah satu bagian penting dalam proses pengolahan data adalah preprocessing. Preprocessing dilakukan untuk mempersiapkan data agar dapat digunakan dengan lebih baik oleh algoritma machine learning. Salah satu proses yang dibahas adalah scaling, yaitu mengubah skala nilai fitur sehingga perbedaan rentang antarfitur tidak terlalu memengaruhi hasil algoritma. Hal ini penting terutama pada algoritma yang menggunakan jarak atau perhitungan berdasarkan besarnya nilai fitur. Beberapa bentuk scaling yang dibahas antara lain standardization, min-max scaling, robust scaling, dan normalisasi.

Standardization mengubah data sehingga setiap fitur memiliki rata-rata mendekati nol dan standar deviasi sebesar satu. Min-max scaling mengubah nilai fitur ke dalam rentang tertentu, sedangkan robust scaling menggunakan ukuran statistik yang lebih tahan terhadap pengaruh outlier. Pemilihan metode preprocessing perlu disesuaikan dengan karakteristik data. Selain itu, apabila data dibagi menjadi data training dan data test, transformasi yang digunakan harus dipelajari dari data training kemudian diterapkan dengan cara yang sama pada data test. Dengan demikian, informasi dari data test tidak ikut memengaruhi proses pembentukan model.

Bab ini juga membahas penerapan transformasi data dan pengaruh preprocessing terhadap supervised learning. Preprocessing tidak hanya digunakan pada unsupervised learning, tetapi juga dapat memengaruhi performa algoritma supervised learning. Perbedaan skala fitur dapat menyebabkan fitur tertentu memiliki pengaruh yang lebih besar dibandingkan fitur lainnya. Oleh karena itu, melakukan preprocessing dengan tepat dapat membantu algoritma bekerja sesuai dengan karakteristik data yang digunakan.

Selanjutnya dibahas dimensionality reduction, feature extraction, dan manifold learning. Teknik-teknik tersebut digunakan untuk mengurangi jumlah dimensi data atau memperoleh representasi data yang lebih sederhana. Pengurangan dimensi dapat membantu proses visualisasi, mengurangi kompleksitas data, serta mempermudah pemahaman terhadap pola yang terdapat di dalam dataset.

Principal Component Analysis atau PCA merupakan salah satu metode dimensionality reduction yang dibahas pada bab ini. PCA mencari arah atau komponen yang mampu menjelaskan variasi terbesar pada data. Data kemudian direpresentasikan menggunakan sejumlah komponen utama yang lebih sedikit daripada jumlah fitur awal. Dengan cara tersebut, informasi penting dari data dapat dipertahankan dalam bentuk yang lebih sederhana. PCA juga dapat digunakan untuk membantu visualisasi data berdimensi tinggi.

Selain PCA, dibahas pula Non-Negative Matrix Factorization atau NMF. NMF melakukan pemfaktoran data dengan batasan bahwa komponen dan koefisien yang dihasilkan harus bernilai non-negatif. Metode ini sesuai untuk data yang seluruh nilainya tidak negatif dan dapat menghasilkan komponen yang lebih mudah diinterpretasikan pada beberapa jenis data. Hasil NMF juga dapat dipengaruhi oleh proses inisialisasi sehingga hasil yang diperoleh dapat berbeda apabila kondisi awalnya berbeda.

Metode lain yang dibahas adalah t-SNE atau t-distributed Stochastic Neighbor Embedding. t-SNE digunakan terutama untuk memvisualisasikan data berdimensi tinggi ke dalam dimensi yang lebih rendah, biasanya dua atau tiga dimensi. Metode ini berusaha mempertahankan hubungan kedekatan antar-data sehingga struktur lokal

pada dataset dapat terlihat lebih jelas. Hasil visualisasi t-SNE dapat membantu melihat apakah terdapat kelompok atau pola tertentu pada data.

Setelah dimensionality reduction, bab ini membahas clustering. Clustering merupakan proses mengelompokkan data berdasarkan kemiripan karakteristik tanpa menggunakan label kelas yang telah ditentukan sebelumnya. Dengan clustering, data yang memiliki karakteristik serupa diharapkan berada dalam kelompok yang sama. Beberapa algoritma clustering yang dibahas adalah k-Means, Agglomerative Clustering, dan DBSCAN.

k-Means merupakan metode clustering yang membagi data ke dalam sejumlah kelompok yang telah ditentukan. Algoritma ini menggunakan pusat kelompok atau centroid dan mengalokasikan data berdasarkan kedekatannya terhadap centroid tersebut. Proses dilakukan secara berulang sampai pembagian kelompok menjadi stabil. Salah satu keterbatasan k-Means adalah metode ini tidak memiliki konsep khusus untuk menangani noise sehingga setiap data akan cenderung dimasukkan ke salah satu cluster.

Agglomerative Clustering menggunakan pendekatan hierarchical clustering. Pada awal proses, setiap data dianggap sebagai cluster tersendiri, kemudian cluster yang memiliki kedekatan digabung secara bertahap. Proses penggabungan tersebut membentuk struktur hierarki yang dapat divisualisasikan menggunakan dendrogram. Dengan melihat dendrogram, jumlah cluster yang digunakan dapat ditentukan berdasarkan struktur pengelompokan yang terbentuk.

DBSCAN memiliki pendekatan yang berbeda karena mengelompokkan data berdasarkan kepadatan. Dua parameter penting pada DBSCAN adalah `eps` dan `min_samples`. `eps` menentukan jarak maksimum yang digunakan untuk mencari tetangga suatu titik, sedangkan `min_samples` menentukan jumlah minimum titik yang diperlukan agar suatu area dianggap cukup padat. Data yang tidak termasuk dalam kelompok kepadatan tertentu dapat ditandai sebagai noise dengan label -1. Perubahan nilai `eps` dapat menyebabkan perubahan jumlah cluster maupun jumlah data yang dianggap sebagai noise.

Untuk mengetahui kualitas hasil clustering, evaluasi dapat dilakukan menggunakan beberapa ukuran. Jika label sebenarnya tersedia, Adjusted Rand Index atau ARI dan Normalized Mutual Information atau NMI dapat digunakan untuk membandingkan hasil clustering dengan label yang diketahui. Jika label sebenarnya tidak tersedia, silhouette coefficient dapat digunakan untuk melihat seberapa baik data berada di dalam cluster masing-masing. Accuracy tidak tepat digunakan secara langsung untuk mengevaluasi clustering karena nomor atau nama cluster tidak memiliki arti tetap dan dapat berubah antarhasil pengelompokan.

Berdasarkan pembahasan pada Bab 3, setiap metode memiliki karakteristik dan penggunaan yang berbeda. Preprocessing digunakan untuk mempersiapkan data, dimensionality reduction digunakan untuk menyederhanakan representasi data, sedangkan clustering digunakan untuk menemukan kelompok yang terdapat pada data. PCA, NMF, dan t-SNE dapat digunakan untuk membantu melihat atau membentuk representasi data berdimensi lebih rendah, sementara k-Means, Agglomerative Clustering, dan DBSCAN digunakan untuk melakukan pengelompokan data dengan pendekatan yang berbeda.

Dengan demikian, proses unsupervised learning tidak hanya bergantung pada pemilihan algoritma, tetapi juga pada tahap persiapan data dan cara mengevaluasi hasilnya. Pemilihan metode perlu mempertimbangkan karakteristik dataset, skala fitur, keberadaan outlier atau noise, bentuk kelompok yang ingin ditemukan, serta tujuan analisis. Pemahaman terhadap setiap tahapan tersebut penting agar hasil pengolahan data dapat diinterpretasikan dengan tepat.